



Fundamentos de Linguagem Python Do Básico a Aplicações de IA

O Desafio da "Alucinação"
e Estratégias Para Mitigá-la

Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

No contexto da IA Generativa, "alucinação" é o termo usado para descrever um fenômeno em que um LLM gera informações que são factualmente incorretas, sem sentido ou completamente inventadas, mas as apresenta com um tom de confiança e autoridade. Esse é um dos maiores riscos de usar IA Generativa (em especial LLMs) sem o devido conhecimento.

Isso acontece porque os LLMs são fundamentalmente "máquinas de previsão de palavras"; seu objetivo principal é gerar a próxima palavra mais provável em uma sequência para formar frases estatisticamente plausíveis e não verificar a veracidade factual do que estão dizendo. A alucinação é um subproduto desse processo: o modelo pode "inventar" uma citação, uma fonte, uma data ou um fato se isso soar coerente e se encaixar no padrão de linguagem que ele está gerando.


Mitigar alucinações é um dos maiores desafios para a adoção segura da IA Generativa. A estratégia mais eficaz é conhecida como "grounding" (aterramento), que força o modelo a basear suas respostas em um conjunto de fatos verificáveis, em vez de depender apenas de sua memória interna (dados de treinamento).

A técnica mais comum para isso é o RAG (Retrieval-Augmented Generation). Com o RAG, antes de o LLM responder, o sistema primeiro recupera trechos de informação relevantes de uma base de dados confiável (como documentos internos de uma empresa ou resultados de busca na web) e, em seguida, insere esses trechos no prompt, instruindo o modelo a usar apenas essa informação para formular sua resposta.

Outras estratégias incluem o fine-tuning (ajuste fino) do modelo em conjuntos de dados de alta qualidade e verificados e o uso de engenharia de prompt para instruir explicitamente o modelo a admitir quando não sabe a resposta (ex: "Se você não souber a resposta, diga 'Eu não sei'"). Além disso, ajustar parâmetros como a "temperatura" do modelo para um valor baixo (próximo de zero) torna as respostas mais focadas e menos "criativas", reduzindo a probabilidade de desvios factuais.

Temos cursos completos de RAG aqui na DSA. RAG que é a principal estratégia hoje para o uso seguro de IA Generativa nas empresas e teremos um exemplo completo no mini-projeto deste capítulo.

Mas lembre-se: Nada substitui o conhecimento para ser capaz de avaliar se a resposta do modelo está correta ou não.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.