



Fundamentos de Linguagem Python Do Básico a Aplicações de IA

O Padrão RAG (Retrieval-Augmented Generation)

Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

RAG (Retrieval-Augmented Generation), ou Geração Aumentada por Recuperação, é uma arquitetura de sistema de IA que combina os pontos fortes dos LLMs (geração de texto fluente) com os pontos fortes dos sistemas de recuperação de informação (acesso a dados factuais e atualizados). Em vez de depender apenas do conhecimento "congelado" que o LLM adquiriu durante seu treinamento (que pode estar incompleto ou desatualizado), o RAG permite que o modelo consulte uma fonte de conhecimento externa antes de gerar uma resposta.


O processo RAG funciona em duas etapas principais: Recuperação (Retrieval) e Geração (Generation). **Primeiro**, quando um usuário faz uma pergunta, o sistema não a envia diretamente ao LLM. Em vez disso, ele usa a pergunta para consultar uma base de conhecimento externa (geralmente um banco de dados vetorial contendo documentos, artigos, manuais, etc.). O sistema "recuperador" encontra os trechos de texto mais relevantes para a pergunta. Em seguida, na etapa de Geração, o sistema "aumenta" o prompt original do usuário, inserindo esses trechos recuperados como contexto. O LLM é então instruído a gerar uma resposta com base apenas nesse contexto fornecido.

O RAG ajuda a tratar dois problemas críticos dos LLMs: alucinações e conhecimento desatualizado. Ao "aterrar" (ground) a resposta do modelo em fatos concretos e recuperados, a probabilidade de alucinação diminui drasticamente. Além disso, permite que os LLMs respondam sobre informações privadas (como documentos internos de uma empresa) ou eventos muito recentes (como notícias de hoje) sem a necessidade de retrainar o modelo inteiro, tornando-o uma arquitetura fundamental para aplicações empresariais de IA.

Temos um curso inteiro dedicado ao RAG:

<https://www.datascienceacademy.com.br/course/inteligencia-aumentada-com-rag-graphrag-e-agentic-rag>

O RAG também é estudado em diversos cursos aqui na DSA, sempre que um projeto requer resultados mais preciso ao aplicar IA Generativa.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.