



Fundamentos de Linguagem Python Do Básico a Aplicações de IA

Embeddings de Texto Transformando Palavras em Vetores Numéricos

Embeddings de Texto são a representação numérica do significado semântico de um pedaço de texto (seja uma palavra, uma frase ou um documento inteiro).

Modelos de Machine Learning, incluindo LLMs, não conseguem processar texto em seu formato original; eles só entendem números (lembre-se, tudo se resume à Matemática. IA é Matemática via programação de computadores).

Embeddings são a técnica que traduz a linguagem humana para a linguagem da máquina. Eles o fazem mapeando palavras ou frases para um vetor, uma longa lista de números (ex: [0.12, -0.45, 0.89, ...]) **em um espaço de alta dimensionalidade** (muitas vezes com centenas ou milhares de dimensões). Em português bem claro: embeddings são matrizes de valores numéricos representando os dados de texto.

O poder dos embeddings vem do fato de que eles capturam o contexto e o significado de uma palavra. Modelos de embedding (como Word2Vec, GloVe ou os baseados em Transformers, como o BERT) são treinados em vastos corpus de texto e aprendem a posicionar palavras usadas em contextos semelhantes próximas umas das outras nesse espaço vetorial.

Por exemplo, os vetores para "gato" e "cachorro" estarão muito próximos, enquanto o vetor para "gato" estará distante do vetor para "computador".

Essa representação permite operações matemáticas com o significado, como nesse famoso exemplo:

$$\text{Vetor(Rei)} - \text{Vetor(Homem)} + \text{Vetor(Mulher)} \Rightarrow \text{Vetor(Rainha)}$$

Ou seja, ao fazer a operação com os vetores que representam as palavras "Rei", "Homem" e "Mulher", encontramos um padrão semântico, no exemplo algo como "Rainha". No fim das contas isso é uma operação com vetores, conforme estudamos no capítulo sobre NumPy aqui mesmo neste curso.


Na prática, os embeddings são o que permitem a busca semântica. Quando você faz uma pergunta a um sistema RAG, o sistema primeiro converte sua pergunta em um vetor (embedding). Em seguida, ele compara esse vetor com os vetores de todos os documentos em sua base de dados para encontrar os documentos cujos vetores estão "mais próximos" (ou seja, são semanticamente mais semelhantes) da sua pergunta, mesmo que não usem as mesmas palavras-chave.

Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

Temos um curso inteiro dedicado a modelos de embeddings aqui na DSA:

<https://www.datascienceacademy.com.br/course/modelos-de-embeddings-e-bancos-de-dados-vetoriais-para-aplicacoes-de-ia-generativa>

Modelos de Embeddings também são estudados em diversos cursos aqui na DSA, sempre que um projeto requer o uso de RAG ao aplicar IA Generativa.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.