



Fundamentos de Linguagem Python Do Básico a Aplicações de IA

Estudo de Caso 3 Construindo Um LLM do Zero Um Guia Didático Para a Arquitetura Transformer

Fundamentos de Linguagem Python Do Básico a Aplicações de IA

Estudo de Caso 3

Construindo Um LLM do Zero Um Guia Didático Para a Arquitetura Transformer

Curso Online, Gratuito e Com Certificado de Conclusão

Tudo que você estudou neste capítulo sobre IA Generativa tem como base uma arquitetura de Deep Learning chamada de "Transformer", descrita no paper de pesquisa **"Attention Is All You Need"** (Atenção é Tudo Que Você Precisa) que introduziu a arquitetura Transformer em 2017, um modelo fundamental para o desenvolvimento dos modernos Large Language Models (LLMs).

Embora muitas das técnicas de IA (incluindo backpropagation) existam há décadas, foi o Transformer que gerou a explosão da IA que vimos nos últimos anos.

O objetivo deste estudo de caso é desmistificar a arquitetura Transformer, explicando seus componentes e princípios operacionais de forma leve, acessível e didática, mas em nível geral.

Caso queira compreender e construir um LLM a partir do zero com as operações matemáticas em Python, isso é ensinado no curso de Deep Learning aqui na DSA. As operações matemáticas são ensinadas no curso de Matemática, também aqui em nosso portal.



Vamos Desvendar o "Transformer": O Motor da IA Moderna

Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

Quase toda Inteligência Artificial Generativa que usamos hoje, como os modelos de linguagem (LLMs), é construída sobre uma arquitetura fundamental chamada Transformer.

Esse modelo foi apresentado em 2017 e mudou completamente o jogo. Antes dele, os modelos de IA eram muito mais lentos e menos eficientes para tarefas de Processamento de Linguagem Natural.

O modelo Transformer foi criado originalmente para resolver problemas de tradução de texto, tarefa típica em Processamento de Linguagem Natural. Abaixo está a arquitetura do modelo conforme consta no paper original:




Figure 1: The Transformer - model architecture.

Paper de pesquisa do Transformer:

<https://arxiv.org/pdf/1706.03762>

Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

1. O Problema Antigo: Ler Palavra Por Palavra

Antes do Transformer, os modelos de IA (chamados RNNs) liam as frases da mesma forma que uma pessoa lendo um livro pela primeira vez: uma palavra de cada vez, em ordem.

Isso criava dois grandes problemas:

- **Lentidão:** O modelo não podia processar um parágrafo inteiro de uma vez. Ele tinha que esperar para ler a primeira palavra antes de poder ler a segunda e assim por diante. Isso tornava o treinamento (o processo de aprendizado) extremamente lento.
- **"Memória Curta":** Em frases muito longas, quando o modelo chegava ao final, ele muitas vezes já tinha "esquecido" o que estava no início.

2. A Grande Ideia do Transformer: Atenção Total

A solução do Transformer foi radical: em vez de processar palavra por palavra, ele olha para a frase inteira de uma só vez.

Para fazer isso, ele usa um mecanismo chamado Atenção (Attention), que nada mais é do que um conjunto de operações com matrizes.

Vejamos uma analogia simples.

Pense na frase: "Eu deixei o dinheiro no banco perto do rio."

Modelo Antigo (RNN): Leria "Eu... deixei... o... dinheiro... no... banco...". Ao chegar em "banco", ele teria que lembrar que leu "dinheiro" antes para adivinhar o significado.

Modelo Transformer (Atenção): Ele olha para todas as palavras de uma vez. Ele vê "banco", "dinheiro" e "rio" ao mesmo tempo. Ele percebe que "dinheiro" está mais conectado a "banco" do que "rio" está, e instantaneamente entende que se trata de um banco financeiro, e não um banco da margem de um rio.

Esse mecanismo de "atenção" permite que cada palavra "converse" com todas as outras palavras da frase simultaneamente, descobrindo quais são mais importantes para o contexto.

3. Como o Transformer é Construído?

Imagine o Transformer como um tradutor profissional que tem duas partes principais:

O Codificador (Encoder): O "Leitor"

- Função: Ler a frase original (ex: em português) e entendê-la profundamente.
- Ele pega a frase e, usando o mecanismo de Atenção, cria uma representação matemática (um conjunto de números) que captura o significado e o contexto de cada palavra.

O Decodificador (Decoder): O "Escritor"

- Função: Pegar o que o "Leitor" entendeu e gerar a nova frase (ex: em inglês).
- Ele escreve a tradução palavra por palavra. A cada nova palavra que ele escreve, ele olha para o que o Codificador entendeu e para as palavras que ele mesmo já escreveu, para garantir que a frase faça sentido.

4. Ingredientes Secretos

Dois conceitos-chave tornam o Transformer tão poderoso: a Atenção de "Múltiplas Cabeças" e a Codificação Posicional. Vamos compreender os conceitos.

A. Atenção de "Múltiplas Cabeças" (Multi-Head Attention)

O Transformer não lê a frase apenas uma vez. Ele usa o que chamamos de "múltiplas cabeças" para lê-la de várias maneiras diferentes ao mesmo tempo.

Analogia: Um Comitê de Especialistas

Imagine que, em vez de um único tradutor, você tem um comitê de 8 especialistas ("cabeças") lendo a mesma frase:

- Especialista 1: Foca apenas na gramática (Quem é o sujeito? Qual é o verbo?).
- Especialista 2: Foca no tom da frase (É uma pergunta? É uma ordem?).
- Especialista 3: Foca em ambiguidades (A palavra "ele" se refere a quem?).

Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

O modelo então combina o conhecimento de todos esses especialistas para obter uma compreensão muito mais rica e profunda da frase.

B. Codificação Posicional (Positional Encoding)

Se o modelo olha para todas as palavras ao mesmo tempo, como ele sabe a ordem delas? (Afinal, "o cachorro mordeu o homem" é muito diferente de "o homem mordeu o cachorro").

A solução é a Codificação Posicional. Antes de qualquer processamento, o modelo "carimba" cada palavra com um código matemático especial, como um número de GPS. Esse código informa ao modelo a posição exata de cada palavra na frase (1ª, 2ª, 3ª, etc.).

Uma curiosidade: o Positional Encoding é uma operação matemática usando seno e cosseno, os mesmos conceitos que você estudou com Tia Teteca no ensino fundamental. 😊

A imagem abaixo demonstra o cálculo do Positional Encoding.

$$PE_{(pos, 2i)} = \sin(pos / 10000^{2i/d_{model}})$$
$$PE_{(pos, 2i+1)} = \cos(pos / 10000^{2i/d_{model}})$$

5. Por que o Transformer Mudou Tudo?


Velocidade (Paralelização): Por olhar para tudo de uma vez, ele pode ser treinado usando o poder máximo das modernas placas de vídeo (GPUs). Isso tornou o processo de treinamento milhões de vezes mais rápido, permitindo a criação de modelos gigantes (LLMs).

Contexto de Longo Alcance: Ele é excelente em conectar palavras que estão distantes uma da outra. Ele pode facilmente entender que o "ele" no final de um parágrafo se refere ao "João" mencionado no início, algo que os modelos antigos não conseguiam fazer.

O Transformer foi a invenção que resolveu os maiores gargalos de velocidade e compreensão de contexto, tornando-se a "placa-mãe" sobre a qual toda a revolução da IA Generativa foi construída.

Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

E sabe o que é mais incrível? A história da IA Generativa está sendo construída neste exato momento, com variações das arquiteturas, novas técnicas, procedimentos, ferramentas, algoritmos e aplicações. Estamos ajudando a escrever a história da IA, uma verdadeira revolução ocorrendo diante dos nossos olhos, o que gera um universo de oportunidades no mercado de trabalho. Isso, claro, para quem estiver devidamente capacitado e preparado!



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.