



Fundamentos de Linguagem Python Do Básico a Aplicações de IA

Mini-Projeto 8 Quando Usar RAG?


Fundamentos de Linguagem Python - Do Básico a Aplicações de IA

O uso de RAG é indicado quando o modelo de linguagem precisa responder com base em informações externas, atualizadas ou específicas, que não estão em seus parâmetros. Ele é essencial em aplicações corporativas, assistentes jurídicos, bots de atendimento, sistemas de busca semântica e qualquer cenário em que o modelo deva consultar conhecimento real em vez de gerar respostas puramente estatísticas.

O processo começa com o **chunking**, que consiste em dividir documentos longos em pequenos blocos de texto (chamados chunks) para facilitar a busca e garantir que o contexto recuperado seja preciso. Cada chunk é então transformado em um vetor numérico por meio dos embeddings, que representam o significado semântico do texto em um espaço multidimensional, textos com significados semelhantes ficam próximos nesse espaço.

Esses vetores são armazenados em um banco vetorial (como FAISS, Pinecone ou Chroma), que permite buscar rapidamente os chunks mais parecidos com a consulta do usuário. Quando o usuário faz uma pergunta, ela também é convertida em vetor, comparada no banco vetorial, e os trechos mais relevantes são recuperados e enviados como contexto adicional para o modelo gerar uma resposta precisa e fundamentada.

Vejamos isso na prática nas aulas a seguir.



Equipe DSA

Muito Obrigado!
Continue Trilhando Uma Excelente Jornada de Aprendizagem.